

Caelum-Agent 项目阶段性报告

日期: 2026-07-11 ~ 2026-07-17 分支: main 测试状态: 681 passed, 0 failed

一、总体进展

本周（7天）共提交 **80+ commits**，变更 **26 个文件**、**+4700 行**、**-223 行**。核心主线是视觉感知系统从 GUI-Actor 切换到 YOLO-SoM，并围绕它建立了完整的 6 级视觉定位降级链、工具基础设施和质量保障体系。

二、核心技术突破

2.1 YOLO-SoM 视觉感知（替代 GUI-Actor）

组件	文件	功能
YoloDetector	<code>ui_detector/yolo_detector.py</code>	OmniParser icon_detect YOLOv8, ~50ms/帧 GPU, 自动 CUDA→CPU 降级
fuse_annotations	<code>ui_detector/fusion.py</code>	OCR 文字框 + YOLO 图标 框 IoU 融合 (>15% 合 并, >5% 去重), 统一归 一化坐标
IconCaptioner	<code>ui_detector/icon_captioner.py</code>	Florence-2 base fine- tune, 为纯图标标记生成 语义描述 (<code>"magnifier"</code> , <code>"close button"</code>)
visualize_som	<code>ui_detector/visualizer.py</code>	归一化坐标→图像像素渲 染, 红色编号标记

感知流水线: 截图 → 逆DPI归一化 → RapidOCR(DirectML GPU) + UIA树 → YOLO自动补偿 (UIA空时) → 融合 → Florence-2标注 → 双图输出 (干净图+标注图)

2.2 6 级视觉定位降级链

UIA Tree (Snapshot + Click)

└ 失败 →

- | | |
|---------------------------------|--------------------|
| [1] DesktopInteract(label=N) | ← YOLO SoM 自动触发 |
| [2] NearbyLabels(label loc) | ← 纯几何三角定位, 零开销 |
| [3] ZoomRegion(size, label loc) | ← 局部原生分辨率重感知 |
| [4] UpgradeVision | ← 全局原生分辨率切换 |
| [5] CaptureWindow(title) | ← PrintWindow 穿透遮挡 |
| [6] PreviewPoints([[x,y],...]) | ← 最终兜底: 坐标猜测+可视化确认 |

2 次连续失败自动强制推进 (`_FAILURE_ESCALATION_NOTICE`), 任何成功重置计数器。

2.3 坐标系归一化

全部模型面朝坐标统一为 **normalized [0,1]**, **(0,0)=左上角**, **(1,1)=右下角**:

- 内部换算简化为一公式: `screen = origin + norm × screen_size`
- 删除了 `screenshot_width/height` 参与坐标转换的旧路径
- 4 位小数精度, 所有工具描述同步更新

2.4 截图编码与分辨率优化

- 编码: JPEG Q=60 → **PNG 无损** (LLM 需要读文字)
- 分层降档: 逆 DPI 归一化后
 - `max_dim > 3840` → 4K (3840×2160)
 - `max_dim > 2560` → 2K (2560×1440)
 - `max_dim > 1920` → 1080p (1920×1080)
 - `≤ 1920` → 保持原样

2.5 OCR GPU 加速

RapidOCR 通过 `onnxruntime-directml` 在 GPU 上运行 (~5.5x 加速, 4.3s→0.8s @2560×1440, RTX 4090 Laptop)。为避免 DirectML 并发崩溃 (两路 ONNX 会话同时

抢 D3D12 设备导致 0xc0000005)，ChromaDB 向量模型锁死在 CPU
(ONNXMiniLM_L6_V2(preferred_providers=["CPUExecutionProvider"]))。

三、工具和功能清单

新增本地工具（10 个）

工具	功能
DesktopInteract	基于 SoM 标注的视觉点击（label=N），支持 click/type/scroll
NearbyLabels	k 近邻标注查询，归一化坐标欧氏距离排序
ZoomRegion	局部区域原生分辨率重感知（3 档: 480/960/1680px）
UpgradeVision	全局切换原生分辨率截图
PreviewPoints	坐标猜测可视化确认（1-3 个候选点）
CaptureWindow	PrintWindow 穿透遮挡窗口捕获
SelfWindow	隐藏/恢复 Agent 自身控制台窗口
FocusGuard	前台窗口焦点守护（AttachThreadInput 方案）
ReadDocument	Kimi Files API 文档提取（PDF/DOCX/PPTX/EPUB/XLSX）
ViewMedia	本地图片/视频上传并原生渲染（ms:// 引用）

子代理（2 个）

子代理	功能
DraftContent	内容写作（persona + Partial Mode 预填充），最多 5 轮修订
GeneratImage	SVG 生成 + CairoSVG 渲染 + LLM 视觉自检，最多 5 轮

学习机制

组件	功能
SkillLearner	成功任务轨迹 → SKILL.md 自动生成/合并（ChromaDB 向量相似度 ≥0.85 合并）

组件	功能
ReflectionEngine	失败任务 → Kimi rethink + SQLite 记录 → 系统提示注入
LearningSettler	中断任务延迟判定（启动时 LLM 判断完成度 → 路由到 Skill 或 Reflection），最多 3 次尝试

四、工程质量

测试

- 681 个测试，0 失败，pytest-xdist 并行执行
- 新增测试覆盖：融合逻辑、图标标注、YOLO 检测器、学习结算、坐标缩放

上游问题处理

- 定位并归档 windows-mcp 的 UnboundLocalError: tree_node 上游 bug ([docs/windows_mcp/upstream-tree-node-issue.md](#))
- `_UpstreamNoiseFilter` 在 MCP 客户端层抑制已知噪声（含 traceback 感知、rich tool-error 块过滤）

稳定性

- LLM 瞬态错误重试 + WARNING 日志
- 过期 UIA 标签自动刷新 Snapshot
- API 断路器（5 次连续失败 trip）
- 循环预算 + 反思检查点（初始 10 轮，最多 50 轮）

五、文档

- [docs/handover/caelum-agent-pro-handover.md](#) — 全面交接文档（930 行）
- [docs/kimi_api/kimi_api_usage.md](#) — Kimi API 使用手册（562 行）
- CLAUDE.md 持续更新

六、下阶段计划

1. **端到端测试:** 完善真实桌面场景的自动化 E2E 测试
2. **WeChat/QQ 适配:** 针对 Qt 无 UIA 应用优化视觉定位准确率
3. **性能优化:** 减少感知延迟 (OCR+YOLO+Florence 串行→流水线)
4. **多模态记忆:** 截图关键帧存入 ChromaDB 辅助长期任务记忆
5. **安全审计:** 文件系统操作权限细粒度控制